

DOCUMENT DE CADRAGE PROJET AI Dataset Studio

La plateforme "Canva des datasets IA"

Nettoyer · Annoter · Fiabiliser · Équilibrer · Exporter

1. Contexte

Le développement de modèles d'intelligence artificielle performants repose avant tout sur la qualité des données qui les alimentent. Pourtant, la préparation des datasets reste aujourd'hui l'une des étapes les plus longues, les plus techniques et les moins outillées du cycle de vie d'un projet IA : nettoyage manuel, annotation fastidieuse, détection d'erreurs approximative, déséquilibre des classes non maîtrisé et formats d'export hétérogènes selon les frameworks cibles.

Cette complexité pénalise particulièrement trois catégories d'acteurs : les chercheurs qui doivent consacrer un temps disproportionné à la préparation de leurs données plutôt qu'à leurs travaux scientifiques, les startups IA qui n'ont pas toujours les ressources pour construire des pipelines de préparation de données robustes, et les universités qui souhaitent offrir à leurs étudiants un outil pédagogique simple pour manipuler des jeux de données réels.

À l'image de ce que Canva a apporté au design graphique qui est rendre accessible à tous un savoir-faire auparavant réservé aux experts, il n'existe pas encore d'équivalent grand public pour la préparation de datasets IA. Les outils actuels sont soit trop techniques (bibliothèques Python nécessitant du code), soit trop spécialisés (un seul type de tâche à la fois), soit réservés aux grandes entreprises disposant d'équipes MLOps dédiées.

2. Objectif

L'objectif du projet AI Dataset Studio est de concevoir et développer une plateforme web intuitive et accessible, permettant à tout utilisateur technique ou non de préparer un dataset prêt à l'entraînement en quelques étapes simples, sans écrire de code.

2.1 Objectif général

Démocratiser la préparation de données pour l'IA en proposant une expérience aussi simple et visuelle que celle d'un éditeur graphique grand public, tout en garantissant la rigueur méthodologique attendue par des utilisateurs exigeants (chercheurs, data scientists).

2.2 Objectifs spécifiques

- Permettre le nettoyage automatisé et semi-automatisé des données (doublons, valeurs manquantes, formats incohérents).
- Offrir un module d'annotation collaboratif et intuitif, adaptable aux données tabulaires, textuelles et images.
- Détecter automatiquement les erreurs et anomalies au sein d'un dataset (labels incohérents, valeurs aberrantes, etc...).

- Analyser et corriger le déséquilibre des classes via des techniques de rééquilibrage configurables.
- Exporter les datasets préparés vers les formats standards utilisés par l'écosystème IA (CSV, JSON, COCO, YOLO, Hugging Face Datasets, etc.).
- Proposer une interface "drag-and-drop", visuelle et guidée, réduisant la barrière technique d'entrée.

3. Démarche globale

Le projet sera conduit selon une démarche itérative en cinq phases, permettant de valider progressivement la pertinence fonctionnelle et technique de la solution avant d'en élargir le périmètre.

1. Phase de cadrage et d'étude des besoins : entretiens avec des utilisateurs cibles (chercheurs, startups, universités), analyse de l'existant (outils concurrents, bibliothèques open-source), définition précise du périmètre fonctionnel et des personas.
2. Phase de conception : élaboration de l'architecture technique (frontend, backend, moteur de traitement des données), conception UX/UI centrée sur la simplicité d'usage, définition du modèle de données et des pipelines de traitement.
3. Phase de développement du MVP : implémentation itérative des modules cœur :import de données, nettoyage, annotation, détection d'erreurs, équilibrage des classes, export avec priorisation des fonctionnalités à plus forte valeur ajoutée.
4. Phase de tests et de validation : tests fonctionnels et de performance sur des jeux de données réels de tailles variées, tests utilisateurs auprès d'un groupe pilote (ex. laboratoire de recherche ou promotion d'étudiants), itérations correctives.
5. Phase de déploiement et de diffusion : mise en production, rédaction de la documentation technique et utilisateur, accompagnement d'un premier cercle d'utilisateurs pilotes, collecte de retours pour les évolutions futures.

Cette démarche s'appuiera sur des cycles courts (sprints) favorisant les retours utilisateurs fréquents, afin d'orienter les priorités de développement en fonction des besoins réels des trois segments de clientèle visés.

4. Livrables attendus

Le tableau ci-dessous synthétise les principaux livrables du projet, depuis le cadrage jusqu'au déploiement pilote.

Livrable	Description
Étude de cadrage	Document de vision (contexte, problème, proposition de valeur, personas, périmètre).
Spécifications fonctionnelles	Cahier des charges détaillant les modules : import, nettoyage, annotation, détection d'erreurs, équilibrage, export.
Maquettes UX/UI	Wireframes et maquettes haute-fidélité de l'interface (inspirées de la simplicité "Canva-like").
Prototype fonctionnel (MVP)	Application web permettant d'importer un dataset, d'appliquer au moins un pipeline de nettoyage/annotation et d'exporter le résultat.
Moteur de qualité des données	Modules de détection d'erreurs (doublons, valeurs aberrantes, labels incohérents) et de rééquilibrage des classes.
Module d'annotation collaboratif	Interface d'annotation manuelle/semi-automatique avec gestion de projets et de contributeurs.
Connecteurs d'export	Export vers les formats standards (CSV, JSON, COCO, YOLO, Parquet, Hugging Face Datasets).
Documentation technique	Architecture, choix technologiques, guide d'installation et de déploiement.
Documentation utilisateur	Guide d'utilisation, tutoriels et exemples de cas d'usage pour chercheurs, startups et universités.
Plan de déploiement & pilote	Stratégie de mise en production et retours d'un groupe pilote (ex. laboratoire de recherche partenaire).

Cibles utilisateurs

- **Chercheurs** : besoin de rigueur méthodologique, de traçabilité des transformations appliquées et de compatibilité avec les formats académiques.
- **Startups IA** : besoin de rapidité de mise en œuvre, de coûts maîtrisés et d'intégration facile dans des pipelines d'entraînement existants.
- **Universités** : besoin d'un outil pédagogique simple, permettant aux étudiants de manipuler des données réelles sans prérequis technique avancé.